实验语料设计说明

一、总体说明

我们总的任务设计参照李倩《语音老化语料设计规范》，陈居强、常辉《汉语失语症患者话语产出的词汇网络建模研究》，韩舒羽等《老年人智慧医疗领域语音生物标记物应用研究》。任务分为三项朗读任务（词语朗读、语句朗读、篇章朗读）和三项自发产生任务（即图片描述、过程叙述、故事讲述）。

二、朗读任务

（一）词语朗读

该任务采用两份词语朗读词表：一份为包含单音节词的单字词表，另一份为包含 449 个双音节词的双字词表。

1、单字词表的基础是李爱军、熊子瑜《SCSC汉语普通话单音节语音语料库》中的词表，原字词共 1273 个。考虑到老年群体的教育水平，我们在此基础上按照下面的要求去掉了某些字词：

（1）明显生僻、脱离老年人日常。如檩 lin3、颟 man1、纂 zuan3、耖 chao4、蹶 jue3、礤 ca3、撙 zun3、谮 zen4、瘥 chai4、铳 chong4、鳔 biao4、逋 bu1、笸 po3、扃 jiong1、蚶 han1、恧 nv4、蒯 kuai3、彖 tuan4、趸 dun3、蕤 rui2、掭 tian4、徂 cu2 等。

（2）方言色彩、口语色彩或地域差异较强。如：夼 kuang3、攮 nang3、嗲 dia3、呒 m2、仨 sa1、啷 lang1、谝 pian3 等。

（3）网站上原数据中显示异常的字词。如：0014 □ yong2、0039 □ eng1、0135 □ mang1、0150 □ zun4、0444 □ rua2、0458 □ kei1、0525 □ m4、1183 □ cei4。

删减后的字表共 1215 个单字词。旨在覆盖普通话中全部四种单字调，即阴平（高平调）、阳平（升调）、上声（降升调）和去声（降调）。各声调对应的单音节词数量及平均对数词汇频率（每百万次）基本平衡：

声调	数量	平均对数词汇频率（每百万次）	标准差
阴平	322	1.85	0.85
阳平	249	2.07	0.83
上声	307	1.93	0.98
去声	337	2.03	0.89
总计	1215		

2、双音节词表共主要参考了李爱军、熊子瑜《SCSC汉语普通话单音节语音语料库》中的词表，考虑到老年群体的教育水平，我们在此基础上按照下面的要求去掉了某些字词，如谔谔、倨傲、白垩、下颚、遐迩、皑皑、狭隘、桀骜、巍峨、徭役、要隘、云霭、喑哑、关隘、建瓯，再与《“现代汉语研究语料库系统”词类频率表》对比，保留了 1872 个词。双音节词表旨在覆盖普通话四种声调的全部 16 种可能组合，声调组合对应的双音节词数量及词汇频率基本平衡：

声调	数量	平均对数词汇频率（每百万次）	标准差
T1T1	195	0.92	0.65
T1T2	252	0.92	0.57
T1T3	195	0.88	0.60
T1T4	352	1.00	0.65
T2T1	164	0.93	0.66
T2T2	189	0.93	0.61
T2T3	165	0.88	0.54
T2T4	310	0.95	0.58
T3T1	107	0.73	0.55
T3T2	139	1.01	0.62
T3T3	103	0.94	0.69
T3T4	203	1.10	0.62
T4T1	191	0.80	0.53
T4T2	250	1.00	0.59
T4T3	232	0.94	0.59
T4T4	408	0.96	0.60
总计	1872		

（二）语句朗读

语句朗读按李倩《语音老化语料设计规范》，选自普通话语音语料库 RASC863。语句选自新闻报道和电视节目脚本，信息结构与韵律结构具有多样性。我们采取了其中 312 句。

（三）篇章朗读

旨在考察朗读较长篇章（连贯语句）时言语流畅度的发展变化，以及言语流畅度对言语韵律的潜在影响。篇章朗读材料为一段简短说明性文字（共四个连续句子，约 100 个音节）。

1、早上出门之前，人们通常会先查看当天的天气预报情况。如果气温明显下降，就需要适当增加衣物来保持身体温暖。如果预报显示可能有降雨，还应随身携带雨伞或其他雨具。通过提前做好这些准备，可以减少天气变化对出行造成的影响。

2、在种植植物之前，需要先选择适合植物生长的土壤类型。然后将种子均匀地放入松软的土壤中，并轻轻覆盖一层泥土。接下来要按照一定的时间间隔进行浇水，并保证充足光照。经过一段时间的持续养护，植物就会逐渐发芽并开始生长。

3、在城市生活中，人们的日常出行通常依赖多种交通方式配合。地铁适合在较长距离内进行快速而稳定的通勤出行活动。公交车则可以覆盖更多街道区域，方便到达不同地点。根据具体情况合理选择交通工具，可以有效提高整体出行效率。

三、自发产出任务

（一）图片描述

来自波士顿诊断性失语症检查（简称 BDAE）中的黑白线描图《饼干失窃》

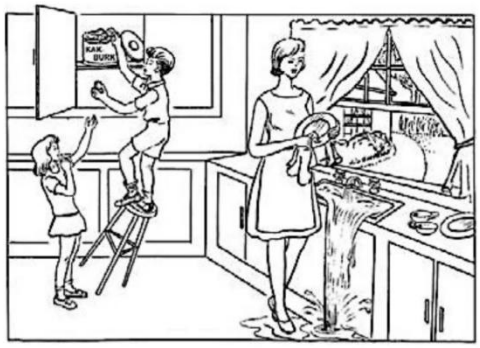

1. 图画中的人物之间是什么关系?
2. 谁背着画中的妈妈在干什么事?
3. 为什么小姑娘不让小男孩弄出声响来?
4. 你为什么认小男孩可能会受伤?
5. 在妈妈的前方正有什么事情发生?

请尽可能详细地描述图片中的信息。

来自 Western Aphasia Battery（WAB 西方失语症测验）

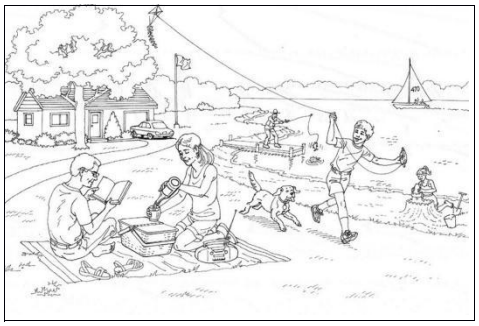

1. 图中正在野餐的两个人可能是什么关系?
2. 奔跑的小男孩手里拿着什么，在做什么?
3. 湖边的那位男士正在进行什么活动?
4. 野餐垫旁的小狗正朝着哪个方向跑去?
5. 看书的男士面前，女士正在做什么动作?

请尽可能详细地描述图片中的信息。

（二）过程叙述

请您描述蛋炒饭制作过程。请尽量按顺序说明：需要哪些材料，先做什么，后做什么，最后怎样完成，尽量说出具体步骤。请自然表达，不需要刻意简短，也不需要追求书面化。

火腿肠蛋炒饭

包饺子

去菜市场买菜

（三）故事讲述

龟兔赛跑

狼来了

乌鸦喝水

参考资料：

1. 李倩，语音老化语料设计规范
2. 陈居强、常辉《汉语失语症患者话语产出的词汇网络建模研究》
3. 韩舒羽等《老年人智慧医疗领域语音生物标记物应用研究》
4. 李爱军、熊子瑜，SCSC汉语普通话单音节语音语料库
5. 李爱军、熊子瑜，WCSC汉语普通话两音节语音语料库
6. 邢红兵，《25 亿字语料汉字字频表》
7. 邢红兵，《“现代汉语研究语料库系统”词类频率表》

评价指标

语音：

1、流畅性

包括图片描述、对话和命题话语等。

通过**语速**、**停顿时长**等时间维度指标以及**替换**、**单词重组**、**重复**、**词汇填充**、**非词汇填充**、**6 秒以上的停顿次数**、**修复和更正**等指标测量。

2、连贯性

基于自然语言处理技术和计算语言学的方法，用整体连贯性和局部连贯性作为评价语篇连贯性的指标。

整体连贯性关注语篇中每个语句与整个讨论主题的关联性，可以通过**计算句子与主题的语义相似度**来评价。局部连贯性更关注相邻语句之间的关联性，可以通过**计算相邻句子之间的词汇重叠**、**语义相似度**、**语法依赖关系和逻辑关系**。

语义：

1、丰富度

网络规模：词汇网络中有多少个节点。节点越多，说明该任务中可进入网络建模的词汇资源越丰富，网络规模也就越大。

核心实词丰富度。

2、组织度

模块度：集群是由连接密度较高的节点形成的结构，集群内部节点之间的连接高于集群外部；模块度则衡量这种集群化程度，模块度越接近 1，说明网络集群性越强，组织性越好

小世界指数（SWI）：主要是用来说明词汇网络是否同时具备两种结构特征：一是局部聚集性高，也就是语义相关的词更容易形成局部团簇；二是整体路径短，也就是网络里存在把较远词汇连接起来的“捷径”，从而使信息传递和加工更有效率。文章把它作为宏观层面的核心指标之一，用来判断失语症患者的话语词汇系统在整体组织上是否还保有人类语言网络的复杂系统特征。